

基于一元线性回归的气温与冷饮销量关系分析

姓名：待填写 学号：待填写

2026 年 9 月 2 日

摘要

本文研究日最高气温与校园冷饮店销量之间的关系。基于连续 15 天的气温和销量数据，首先进行缺失值检查与描述性统计，然后计算 Pearson 相关系数，并建立一元线性回归模型。结果表明，气温与销量呈显著的正相关，相关系数为 0.9985；所建立模型的决定系数为 0.9970，均方根误差为 1.0370 杯。结果说明在当前样本范围内，气温升高通常伴随着冷饮销量增加，且一元线性回归模型具有良好的样本内拟合效果。该模型可以用于辅助短期销量预测与备货决策，但受样本数量较少、影响因素有限等条件约束，结论仍需结合更多数据进一步验证。

关键词：一元线性回归；Pearson 相关系数；冷饮销量；数据分析

1 问题重述

某校园冷饮店记录了连续 15 天的日最高气温与冷饮销量。需要利用已有数据分析气温与销量之间的关系，并建立一个简单模型描述两者之间的数量关系。具体任务包括：检查数据质量，计算描述性统计量与相关系数，建立一元线性回归模型，评价模型的拟合效果，并讨论模型的实际意义和局限性。

2 数据分析与预处理

2.1 数据说明

数据共包含 15 条观测和 3 个字段，其中用于建模的两个主要变量如表 1 所示。另一个字段为观测日序号，用于标识样本顺序，不直接参与回归建模。

表 1: 主要变量及其含义

变量	含义	单位
x	日最高气温	°C
y	当日冷饮销量	杯

2.2 数据检查

使用 Python 对数据规模、数据类型和缺失值进行检查。结果显示，日序号、日最高气温和冷饮销量三个字段的缺失值数量均为 0，数据记录完整。同时结合变量的取值范围进行初步检查，气温位于 18 至 32 °C 之间，销量位于 82 至 141 杯之间，未发现明显不合理的数据，因此保留全部样本用于后续分析。

2.3 描述性统计

气温和销量的描述性统计结果如表 2 所示。

表 2: 主要变量的描述性统计

变量	均值	标准差	最小值	最大值
气温	25.000	4.472	18	32
销量	109.867	19.467	82	141

由表 2 可知，样本期间气温位于 18 至 32 °C 之间，冷饮销量位于 82 至 141 杯之间。气温与销量均具有一定的变化范围，可以用于初步分析两个变量之间的数量关系。

3 模型建立与求解

3.1 分析流程

本文的完整分析流程如图 1 所示。




图 1: 气温与冷饮销量关系分析流程

3.2 相关分析

采用 Pearson 相关系数衡量气温与销量之间的线性相关程度:

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}. \quad (1)$$

计算得到 $r = 0.9985$ 。该系数为正且非常接近 1，说明在当前样本中，日最高气温与冷饮销量之间存在很强的正线性相关关系，即较高气温通常对应较高销量。需要指出的是，相关系数只能反映变量之间的统计关联，不能仅凭该结果证明气温变化是销量变化的唯一原因。

3.3 一元线性回归模型

以日最高气温 x 为自变量，以冷饮销量 y 为因变量，建立一元线性回归模型:

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad (2)$$

其中， β_0 为截距， β_1 为回归系数， ε_i 为随机误差。使用最小二乘法估计模型参数，得到拟合方程:

$$\hat{y} = 1.2060 + 4.3464x. \quad (3)$$

斜率的实际意义是：在当前数据范围和其他影响因素未被单独控制的条件下，日最高气温每升高 1°C ，模型预测冷饮销量平均增加约 4.35 杯。截距表示气温为 0°C 时的形式预测值，但该温度超出本样本的观测范围，因此不宜作过强的实际解释。

3.4 模型评价指标

采用决定系数 R^2 和均方根误差 RMSE 评价模型:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}, \quad (4)$$

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}. \quad (5)$$

R^2 越接近 1, 说明模型对样本中销量变化的解释程度越高; RMSE 越小, 说明预测值与真实值之间的平均偏差越小。

4 结果分析

原始观测数据和回归模型的拟合结果如图 2 所示。




图 2: 气温与冷饮销量的散点图及线性拟合结果

由图 2 可知, 各观测散点随气温升高呈明显上升趋势, 并且整体紧密分布在拟合直线附近, 仅存在幅度较小的上下波动。模型的决定系数为 $R^2 = 0.9970$, 说明该线性模型能够解释当前样本中约 99.70% 的销量变异; RMSE 为 1.0370 杯, 表示样本内模型预测值与实际销量之间的典型偏差约为 1.04 杯。综合相关系数、 R^2 和 RMSE, 可以认为该模型对当前 15 天数据具有良好的线性拟合效果, 但仍需使用更多独立数据检验其未来预测能力。

5 结论与不足

本文利用 15 天观测数据分析了日最高气温与冷饮销量之间的关系。研究表明, 两者存在很强的正线性相关关系, 拟合方程为 $\hat{y} = 1.2060 + 4.3464x$; 在当前样本范围内, 气温每升高 1°C , 模型预测冷饮销量平均增加约 4.35 杯。模型的 R^2 为 0.9970、RMSE 为 1.0370 杯, 表明其样本内拟合误差较小。建立的一元线性回归模型形式简单, 能够直观描述气温变化与销量变化之间的数量关系, 可为冷饮店的短期备货提供初步参考。

本模型仍存在以下不足: 第一, 样本数量较少, 数据只覆盖 15 天; 第二, 销量还可能受到降雨、节假日、促销和客流量等因素影响; 第三, 当前分析得到的是统计相关关系, 不能单独证明因果关系。后续可以收集更长时间的数据, 并引入其他影响变量建立多元回归或时间序列模型。

参考文献

- [1] Harris C R, Millman K J, van der Walt S J, et al. Array programming with NumPy[J]. Nature, 2020, 585: 357–362.

A Python 核心代码

```
"""气温与冷饮销量分析：描述统计、相关分析、一元线性回归与绘图。"""
```

```
from pathlib import Path
```

```
import matplotlib.pyplot as plt
```

```
import numpy as np
```

```
import pandas as pd
```

```
import scienceplots
```

```
PROJECT_DIR = Path(__file__).resolve().parent
```

```
DATA_PATH = PROJECT_DIR / "data" / "daily_sales.csv"
```

```
FIGURE_PATH = PROJECT_DIR / "figures" / "scatter_fit.pdf"
```

```
# 1. 读取数据，并确认建模所需字段存在
```

```
data = pd.read_csv(DATA_PATH)
```

```
required_columns = {"temperature", "sales"}
```

```
missing_columns = required_columns - set(data.columns)
if missing_columns:
    raise ValueError(f"数据缺少必要字段: {sorted(missing_columns)}")

print("前五行数据: ")
print(data.head())

# 2. 取自变量 x (日最高气温) 和因变量 y (冷饮销量)
x = data["temperature"].to_numpy()
y = data["sales"].to_numpy()

# 3. 检查数据规模、缺失值和变量取值范围
row_count, column_count = data.shape
missing_count = data.isna().sum()

print("\n数据规模: ")
print(f"行数: {row_count}")
print(f"列数: {column_count}")
print("每列缺失值数量: ")
print(missing_count)

print("\n取值范围: ")
print(f"气温: {x.min():.0f} 至 {x.max():.0f} °C")
print(f"销量: {y.min():.0f} 至 {y.max():.0f} 杯")

# 4. 计算气温和销量的均值、样本标准差、最小值与最大值
descriptive_stats = (
    data[["temperature", "sales"]]
    .describe()
    .loc[["mean", "std", "min", "max"]]
)

print("\n描述性统计: ")
print(descriptive_stats.round(3))

# 5. 计算 Pearson 相关系数, 衡量两个变量的线性相关程度
```

```
correlation = np.corrcoef(x, y)[0, 1]
print(f"\nPearson 相关系数 r: {correlation:.6f}")

# 6. 使用最小二乘法拟合  $y = \text{slope} * x + \text{intercept}$ 
slope, intercept = np.polyfit(x, y, 1)
print(f"回归斜率: {slope:.6f}")
print(f"回归截距: {intercept:.6f}")
print(f"拟合方程:  $y_{\text{hat}} = \text{intercept:.6f} + \text{slope:.6f} * x$ ")

# 7. 计算样本预测值和残差
y_pred = slope * x + intercept
residuals = y - y_pred

# 8. 计算决定系数  $R^2$  和均方根误差 RMSE
sse = np.sum(residuals**2)
sst = np.sum((y - np.mean(y)) ** 2)
r_squared = 1 - sse / sst
rmse = np.sqrt(np.mean(residuals**2))

print(f"决定系数  $R^2$ : {r_squared:.6f}")
print(f"均方根误差 RMSE: {rmse:.6f} 杯")

# 9. 使用 SciencePlots 绘制原始散点和拟合直线
# no-latex 让绘图不依赖本机 LaTeX; 横坐标排序可避免折线来回连接。
plt.style.use(["science", "no-latex"])
sorted_index = np.argsort(x)

fig, ax = plt.subplots(figsize=(6, 4))
ax.scatter(
    x,
    y,
    color="#2878B5",
    s=35,
    label="Observed data",
    zorder=3,
)
```

```
ax.plot(
    x[sorted_index],
    y_pred[sorted_index],
    color="#C82423",
    linewidth=1.8,
    label="Fitted line",
)
ax.set_xlabel(r"Temperature ( $^{\circ}\text{C}$ )")
ax.set_ylabel("Sales (cups)")
ax.legend()
ax.grid(alpha=0.25)

# 10. 创建图片目录，将矢量图保存为 PDF，然后显示图形
FIGURE_PATH.parent.mkdir(parents=True, exist_ok=True)
fig.savefig(FIGURE_PATH, bbox_inches="tight")
print(f"\n拟合结果图已保存至: {FIGURE_PATH}")
plt.show()
```